Memoria final: Nada sin fuente (semana 3)

Juan David Cacua y Camilo Velandia · Oct 16, 2026

1. Diagnóstico

La IA nos falló de seis formas, todas detectadas al contrastar con el resultado del código o con el PDF original.

#	Quién	Fallo	Detección
1	Juan	Función de R mal usada (`tidy`)	Al ejecutar el código
2	Juan	Regresión politómica en vez de logística ordinal	Comparando respuestas de Gemini
3	Juan	Gráfico con factores desordenados	Al mirar el gráfico
4	Camilo	Diapositiva 7 citaba a Abdelrahman, el PDF era de Trento et al. (2025)	Cada cita contra su PDF
5	Camilo	Tres referencias con autores mal escritos o ausentes	PDF y DOI
6	Camilo	NotebookLM citó los kappas de Miskin sin tener ese PDF cargado	Búsqueda en los PDF con `pdftotext`

El costo fue tiempo de revisión, no un entregable dañado. Lo habría evitado: fijar el orden de los factores y dar más contexto (1 a 3), verificar cada PDF y usar un gestor de referencias (4 y 5), y registrar qué documentos hay cargados en cada prueba (6). Que Chai et al. no apareciera en una búsqueda no probaba que no existiera: el PDF real apareció después.

2. Experimento y decisión

Comparamos **A** chat sin fuentes, **B** buscador con bases reales y **C** contexto cerrado (NotebookLM con nuestro corpus), sobre dos consultas bibliográficas (acuerdo interobservador en estenosis lumbar y deep learning con RSNA 2024). Clasificamos 30 referencias, 5 por tratamiento y consulta, cada una por los dos integrantes por separado. «Utilizable» significa que la referencia existe, los autores y la revista son reales y el contenido citado aparece en la fuente; esa definición no estaba escrita y la fijamos ahora.

Elegimos **NotebookLM** frente a un Proyecto con archivos: ganó en contexto cerrado, cita con localización y costo, empató en privacidad y exportación APA 7, y perdió en reproducibilidad, que compensamos documentando el protocolo.

3. El sistema

NotebookLM con 10 PDF (Miskin, Abdelrahman, Chai, Cai, Richards, Al-Tameemi, Bagley, Zhao y Zhu, Trînc, Trento; DOI en `referencias.bib`), plan gratuito. No controlamos los embeddings ni cuántos fragmentos recupera. El protocolo v1.0 no se ejecutó: cada pregunta se pegó sola y solo estaba activa la configuración del chat, que dice «11 documentos» cuando son 10; la v1.1 describe lo realmente hecho. El notebook tiene solo el resumen de una página de Miskin, y faltan las fechas de carga de cada fuente.

4. Evaluación

Con 30 referencias y 18 preguntas no podemos afirmar que NotebookLM sea más exacto que un chat sin documentos. Lo demostrado es un fallo concreto de citas y un registro auditable de respuestas.

Tratamiento	Utilizables	IC 95 % de Wilson
A: sin fuentes	10 de 10	72,2 % a 100 %
B: buscador	10 de 10	72,2 % a 100 %
C: NotebookLM	9 de 10	59,6 % a 98,2 %

Los intervalos se superponen. El 100 % de A es optimista, porque solo se comprobó que las referencias existieran. El acuerdo entre nosotros fue de 28 de 30 (93,3 %), con kappa de Cohen de −0,034: cada uno marcó un caso no utilizable distinto (tabla 28/1/1/0), así que el kappa no informa sobre los casos problemáticos. En los dos desacuerdos prevaleció la clasificación de Camilo.

Caso de fallo. NotebookLM atribuyó a fuentes del corpus los kappas de Miskin et al. (0,702; 0,544; 0,557; 0,323) con una cita `[5]`, pero ese PDF se cargó un día después de la consulta (fecha confirmada por Juan; el mecanismo no está demostrado). Con Miskin ya cargado, la pregunta 13 los citó bien. Walsh et al. (2026), fuera del corpus, fue una abstención correcta, no un fallo.

Banco de 18 preguntas (14 con respuesta y 4 de abstención). NotebookLM y el control (Claude.ai sin documentos, con búsqueda web) sacaron 17 de 18 (IC 95 % 74,2 % a 99,0 %): el corpus no da ventaja de exactitud, porque las preguntas salen de artículos públicos; sí da trazabilidad. La única no utilizable es la 17: NotebookLM presentó los

antiinflamatorios como tratamiento de primera línea citando a Bagley et al., sin aclarar que no tiene la guía NASS (el resultado se corrigió). La 14 se mantiene «utilizable» con reserva, pues sus cifras extra son de estudios individuales. Camilo clasificó las 18 respuestas literales (`respuestas_notebooklm_2026-10-17.pdf`) y Juan las revisó, así que no fue independiente y no reportamos kappa.

Limitaciones: intervalos anchos, control con búsqueda web, falta registrar por pregunta el pasaje citado y la fecha, y el acta de auditoría cruzada sigue abierta hasta que el equipo auditor la cierre.

5. Qué corregimos de nuestro anteproyecto

Revisamos las diapositivas 7, 8 y 9 contra su fuente. Dos errores fueron nuestros (filas 7.1 y 7.2).

Fila	Fuente	Corrección
7.1	Trînc et al. (2026)	Citar los cuatro autores (no «Preprints»); nuestra primera corrección negaba el desbalance de datos, pero sí lo menciona (pp. 4, 9, 10, 31); son cinco pipelines de Vision Transformers, no modelos estadísticos
7.2	Trento (2025) y Abdelrahman (2026)	La frase mezcla dos fuentes: citar ambas o dividirla; revista *Journal of Smart Algorithms and Applications*
7.3	Furman (2024)	Fuente terciaria que nunca leímos: se retira junto con la frase
8.1	Miskin et al. (2021)	Sí existe y respalda la diapositiva (pp. 1485 a 1492)
8.2	Al-Tameemi et al. (2017)	Agregar el resultado: kappa de 0,40 a 0,60
8.3	Walsh, Lee, Lipetz y Walz (2026)	Autores mal separados; solo se leyó el resumen
Bib.	Cai et al. (2020)	Autor «Cai, X.-y.», no «Xin Yi, C.»

Seis de las ocho filas de trazabilidad ya indican la página; la 7.3 se elimina y la 8.3 sigue pendiente.

6. Declaración de uso de IA

Usamos tres sistemas: el agente de consultoría bioestadística (`gemini-3.6-flash`), objeto de estudio; Claude, para auditar, diseñar el experimento y redactar; y NotebookLM, el sistema evaluado. Contrastamos el código ejecutándolo y las afirmaciones con las fuentes, pero la auditoría mostró fallos en dos puntos hechos con apoyo de IA (filas 7.1 y 7.2). No afirmamos que todo fue contrastado: afirmamos que lo detectamos y corregimos, y que el banco no se apoya en clasificación independiente. Detalle en `DECLARACION_uso_de_IA.md`.