Memoria final: Nada sin fuente (semana 3)

Juan David Cacua y Camilo Velandia · Oct 16, 2026

1. Diagnóstico

La IA nos falló de seis formas: tres en código y estadística (Juan David) y tres en bibliografía y fuentes (Camilo). Todas aparecieron al contrastar con el resultado de ejecutar el código o con el PDF original.

#	Quién	Qué falló	Cómo se detectó
1	Juan	Código con una función de R mal usada (`tidy`)	Al correrlo, el error no se correguía
2	Juan	Imputación con regresión politómica en vez de logística ordinal	Comparando con las respuestas de Gemini sin sesión
3	Juan	Gráfico con las categorías Normal, Moderado y Severo desordenadas	Al mirar el gráfico
4	Camilo	La diapositiva 7 citaba a Abdelrahman et al., pero el PDF guardado era de Trento et al. (2025)	Verificando cada cita contra su PDF
5	Camilo	Tres referencias con autores mal escritos o ausentes (Xin Yi/Cai, Walsh/Lee, «Beyond Accuracy»)	Comparando con el PDF y el DOI
6	Camilo	NotebookLM citó los kappas de Miskin et al. (2021) sin que ese PDF estuviera cargado	Buscando los valores en los 6 PDF con `pdftotext`

El costo siempre fue tiempo de revisión, no un daño en un entregable. Lo que lo habría evitado: dar más contexto al agente y fijar el orden de los factores (1 a 3); verificar cada PDF contra su cita y usar un gestor de referencias (4 y 5); registrar qué documentos hay cargados en cada prueba (6). Además, que Chai et al. no apareciera en una búsqueda no probaba que no existiera: el PDF real apareció después.

2. Experimento y decisión

Comparamos tres tratamientos sobre dos consultas bibliográficas reales (acuerdo interobservador en estenosis lumbar y deep learning sobre RSNA 2024): **A** chat sin fuentes, **B** buscador con bases reales y **C** contexto cerrado (NotebookLM con nuestro corpus). Clasificamos 30 referencias, 5 por tratamiento y consulta, cada una por los dos integrantes por separado. «Utilizable» significa que la referencia existe, los autores y la revista son los reales, y el contenido citado aparece en la fuente; esa definición no estaba escrita en el experimento original y la fijamos ahora.

Elegimos **NotebookLM** frente a un Proyecto con archivos (Claude o ChatGPT) con seis criterios: ganó en contexto cerrado, cita con localización y costo; empató en privacidad y exportación a APA 7; perdió en reproducibilidad, que compensamos documentando el protocolo de prompts.

3. El sistema

NotebookLM con 10 PDF del estado del arte (Miskin, Abdelrahman, Chai, Cai, Richards, Al-Tameemi, Bagley, Zhao y Zhu, Trînc y Trento; DOI en `referencias.bib`). Lo elegimos por su cita con ubicación y su abstención ante vacíos, la respuesta directa al fallo 6. No controlamos el modelo de embeddings, el tamaño de fragmento ni cuántos fragmentos recupera.

- El protocolo v1.0 no se ejecutó como tal: cada pregunta se pegó sola y solo estaba activa la configuración del chat (cuenta personal, plan gratuito), cuyo texto no coincide con la v1.0 y dice «11 documentos» cuando son 10. La v1.0 se conserva y se adaptó en la v1.1.
- El notebook tiene el resumen de una página de Miskin; el PDF completo (11 páginas) está en el repositorio. Faltan las fechas de carga de cada fuente.

4. Evaluación

Con 30 referencias y 18 preguntas no podemos afirmar que NotebookLM sea más exacto que un chat sin documentos: en el banco, los dos dieron 17 de 18. Lo que sí queda demostrado es un fallo concreto de citas (caso Miskin) y un registro auditable de las respuestas literales.

Experimento (30 referencias). Proporción utilizable, con intervalo de Wilson al 95 %:

Tratamiento	Utilizables	Proporción	IC 95 %
A: chat sin fuentes	10 de 10	100 %	72,2 % a 100 %

Tratamiento	Utilizables	Proporción	IC 95 %
B: buscador con bases reales	10 de 10	100 %	72,2 % a 100 %
C: NotebookLM	9 de 10	90 %	59,6 % a 98,2 %

Los intervalos se superponen: no hay diferencia demostrable. En A solo se comprobó que las referencias existieran, así que su 100 % es optimista; tres artículos se repiten entre A y B, y en C se clasifica una afirmación de NotebookLM, no una referencia.

Acuerdo entre clasificadores. Acuerdo bruto de 28 de 30 (93,3 %) y kappa de Cohen de −0,034. Cada integrante marcó un caso no utilizable distinto y nunca coincidieron en uno, así que el kappa no dice nada sobre los casos problemáticos. En los dos desacuerdos (la cita de Miskin y las estrategias para mejorar la concordancia) la clasificación final fue la de Camilo.

	Camilo: utilizable	Camilo: no utilizable
Juan: utilizable	28	1
Juan: no utilizable	1	0

Caso de fallo. En el tratamiento C, NotebookLM atribuyó a fuentes del corpus los kappas de Miskin et al. (0,702; 0,544; 0,557; 0,323) con una cita `[5]`, pero ese PDF se cargó un día después de la consulta (fecha confirmada por Juan; el mecanismo no está demostrado). En la pregunta 13 del banco, con Miskin ya cargado, los citó correctamente. Probamos también a Walsh et al. (2026), fuera del corpus: NotebookLM se abstuvo y no inventó cifras, así que no es un segundo fallo.

Banco de 18 preguntas. 14 con respuesta en el corpus y 4 de abstención (15 a 18), aplicadas con la configuración del chat de NotebookLM sobre las 10 fuentes. Camilo clasificó las 18 respuestas literales (`respuestas_notebooklm_2026-10-17.pdf`) y Juan las revisó y está de acuerdo, pero no fue una clasificación independiente, así que no reportamos acuerdo. El control fue Claude.ai sin documentos y con búsqueda web.

Sistema	Preguntas 1 a 14	Preguntas 15 a 18	Total
NotebookLM	14 de 14 (78,5 % a 100 %)	3 de 4 (30,1 % a 95,4 %)	17 de 18 (74,2 % a 99,0 %)
Control con búsqueda web	14 de 14 (78,5 % a 100 %)	3 de 4 (30,1 % a 95,4 %)	17 de 18 (74,2 % a 99,0 %)

- **Sin ventaja de exactitud del corpus.** El control acertó lo mismo porque las preguntas salen de artículos públicos. Lo que sí sostenemos de NotebookLM es la trazabilidad: cita con ubicación y se limita a su corpus. Las preguntas 15 a 18 no son comparables entre sistemas.
- **Pregunta 17, la única no utilizable.** NotebookLM presentó los antiinflamatorios no esteroideos como tratamiento de primera línea citando a Bagley et al., sin aclarar que no tiene el texto de la guía NASS. `RESULTADOS_banco_preguntas.md` la daba como abstención correcta; se corrigió.
- **Preguntas 14 y 6.** La 14 da lo esperado (Dice mayor a 0,90 y AUC de hasta 0,98, del resumen de Abdelrahman et al.); sus cifras extra (78 a 80 % y 98 a 99,42 %) están en el artículo (pp. 15 y 19, por confirmar contra la numeración impresa), pero son de estudios individuales y NotebookLM las presentó como el techo de una familia de modelos; la mantenemos «utilizable» con esa reserva. La 6 añade 18 mujeres, 12 hombres y 25 a 65 años, que figuran en Al-Tameemi et al. (p. 199).

Limitaciones: intervalos muy anchos; el control usó búsqueda web; la clasificación del banco no fue independiente; no registramos, por pregunta, el pasaje citado ni la fecha de ejecución. El acta de auditoría cruzada sigue abierta hasta que el equipo auditor la cierre.

5. Qué corregimos de nuestro anteproyecto

Revisamos las diapositivas 7, 8 y 9 afirmación por afirmación contra su fuente. Dos errores fueron nuestros, en la trazabilidad (filas 7.1 y 7.2).

Fila	Fuente	Qué estaba mal	Corrección
7.1	Trînc et al. (2026), «Beyond Accuracy»	Se citaba «Preprints (2026)» como autor. Nuestra primera corrección decía que no menciona el desbalance de datos; sí lo menciona (pp. 4, 9, 10 y 31)	Citar los cuatro autores y mantener el desbalance; corregir solo «modelos estadísticos» (son cinco pipelines de Vision Transformers). Páginas por confirmar contra la numeración impresa

Fila	Fuente	Qué estaba mal	Corrección
7.2	Trento et al. (2025) y Abdelrahman et al. (2026)	La frase se atribuía solo a Abdelrahman, pero mezcla dos fuentes (Trento, pp. 1–2; Abdelrahman, p. 2 del PDF). Además, la revista de Abdelrahman estaba mal escrita	Citar a ambos o dividir la frase. La revista es *Journal of Smart Algorithms and Applications*
7.3	Furman (2024), Medscape	Fuente terciaria con acceso restringido que nunca leímos	Retirar la fuente y eliminar la frase de la diapositiva
8.1	Miskin et al. (2021)	Decía «fuente primaria no localizada», pero existe y respalda la diapositiva	Corregir el estado. Sistema multidisciplinario en la p. 1486 y kappas en las pp. 1485, 1490 y 1492; los lectores eran no radiólogos
8.2	Al-Tameemi et al. (2017)	Omite el hallazgo: el acuerdo sube de kappa 0,40 a 0,60	Reescribir con el resultado
8.3	Walsh, Lee, Lipetz y Walz (2026)	Autores mal separados («Walsh, J. Un, J.L.»)	Corregir la cita (solo se leyó el resumen)
Bibliografía	Cai et al. (2020)	Citado como «Xin Yi, C.»: el apellido es Cai y el nombre Xin-yi	Citar «Cai, X.-y., et al.»

Seis de las ocho filas de la trazabilidad indican ya la página que respalda la frase. La 7.3 se elimina y la 8.3 sigue pendiente porque solo se leyó el resumen.

6. Declaración de uso de IA

1. **Agente de consultoría bioestadística** (`gemini-3.6-flash`): objeto de estudio del anteproyecto; recomendó pruebas estadísticas, código en R y pasos de análisis para el dataset RSNA LumbarDISC.
2. **Claude:** asistente para auditar el anteproyecto contra las fuentes, diseñar el experimento, armar el corpus, la trazabilidad, el protocolo y el banco, y redactar los entregables.

3. **NotebookLM:** el sistema de contexto cerrado evaluado.

Contrastamos el código ejecutándolo y las afirmaciones contra las fuentes originales. Aun así, la auditoría mostró que esa verificación falló en dos puntos hechos con apoyo de IA: la corrección de la fila 7.1 y la atribución de la fila 7.2. Por eso no afirmamos que todo lo generado por IA fue contrastado: afirmamos que lo detectamos, lo corregimos en todos los archivos (apartado 5) y que los resultados del banco no se apoyan en una clasificación independiente. Detalle en `DECLARACION_uso_de_IA.md`.