

Proyecto de consultoría USTA 2026-II

Revisión de fuentes

Evaluación de sistemas de IA y trazabilidad del estado del arte

Actividad Corte 2

Qué se hizo, por qué, cómo se comprobó y qué no se garantiza

Autores

Juan David Cagua · Camilo Velandia

Fecha

Documento consolidado: 7 de octubre de 2026

Asignatura:	Consultoría Estadística
Propósito:	Evaluar sistemas de IA con contexto cerrado y construir el sistema de fuentes del anteproyecto
Caso de estudio:	Estenosis lumbar y conjunto RSNA 2024
Herramientas de IA:	Gemini 3.6 Flash · Claude Sonnet 5.5 · NotebookLM
Contenido:	6 fallos · 18 preguntas · 30 referencias · 10 fuentes · 8 afirmaciones trazadas
Estado:	Consolidado; con 10 observaciones y 5 acciones pendientes (Sección 9)

Este documento consolida la actividad del Corte 2. Las cifras de intervalos y de acuerdo se recalcularon durante el análisis; las observaciones que no figuraban en el original están en la Sección 9.

Índice

1. Resumen ejecutivo	3
2. Contexto y alcance	4
2.1. El propósito manda.....	4
2.2. Equipo y herramientas	4
2.3. Marco de referencia	4
3. Inventario de fallos	5
3.1. Qué se registró	5
3.2. Qué enseña el inventario	5
4. Banco de preguntas de evaluación	6
4.1. Preguntas con respuesta en el corpus.....	6
4.2. Preguntas de abstención.....	7
5. El experimento	8
5.1. Diseño	8
5.2. Resultados.....	8
5.3. Interpretación	9
6. Herramienta elegida y comparación	9
7. Sistema de fuentes	10
7.1. Tabla de fuentes.....	10
7.2. Tabla de trazabilidad.....	10
8. Protocolo de prompts (v1.0)	12
9. Observaciones del análisis y acciones pendientes	12
9.1. Observaciones	13
9.2. Qué permite concluir el experimento.....	14
9.3. Acciones pendientes	14
10. Declaración del uso de IA	14
Referencias	15
Anexo A	16
Anexo B	17

Cómo leer este documento

Si usted es...	Lea	Tiempo
Docente o evaluador	Secciones 1, 5 y 9	10 min
Integrante que usará el sistema de fuentes	Secciones 1, 7 y 8	15 min
Revisor técnico	Todo el documento y los anexos	40 min
Quien retome el proyecto	Secciones 9, 7 y 8	15 min

Los términos técnicos están en el glosario (Anexo A).

1. Resumen ejecutivo

Para qué. La actividad busca que el equipo aprenda a usar sistemas de inteligencia artificial (IA) en consultas bibliográficas sin perder el control de la evidencia: documentar sus fallos, medir cuánto se puede confiar en cada tipo de sistema y dejar un sistema de fuentes que cualquiera pueda verificar. El caso de trabajo es el anteproyecto sobre estenosis lumbar y el conjunto de datos RSNA 2024, en particular su sección «Estado del arte» (diapositivas 7 a 9).

Qué se hizo. Cada integrante registró al menos tres fallos propios, con lo que se consolidaron seis (Tabla 2). Se armó un banco de 18 preguntas con respuesta localizada en el corpus, cuatro de ellas deliberadamente fuera de él para probar la abstención (Tablas 3 y 4). Se comparó, en dos consultas reales, un chat sin fuentes (A), un buscador con bases reales (B) y un sistema de contexto cerrado, NotebookLM con el corpus del equipo (C); se clasificaron 30 referencias de forma independiente (Tabla 6). Se construyó una tabla de diez fuentes y una de trazabilidad que contrasta ocho afirmaciones de las diapositivas contra los textos reales (Tablas 8 y 9), y se redactó la versión 1.0 del protocolo de prompts (Tabla 10).

Qué se encontró. Las proporciones de referencias utilizables fueron 100 % (A), 100 % (B) y 90 % (C). El único caso no utilizable fue un fallo real del sistema: NotebookLM citó valores de Miskin et al. (2021) cuando ese PDF todavía no estaba cargado en el notebook. El acuerdo bruto entre clasificadores fue de 93,3 % (28/30). En la trazabilidad, cuatro afirmaciones coinciden con su fuente, una está respaldada por la fuente aunque el sistema falló (8.1), dos quedan pendientes o coinciden solo en parte (7.1 y 7.2) y una fuente se retiró por ser terciaria (7.3).

Qué no está garantizado (detalle en la Sección 9).

Con diez referencias por tratamiento y un solo caso negativo, el experimento no permite afirmar que un sistema sea mejor que otro; los intervalos de confianza se solapan casi por completo. Además, el análisis de este documento identificó diez observaciones (Sección 9); las más importantes son que el kappa reportado solo es aritméticamente compatible con que cada integrante marcara una referencia distinta como no utilizable, que el criterio «utilizable» no está definido operativamente y que solo una de las cuatro preguntas de abstención se ha probado.

Tabla 1. Cifras principales de la actividad

Indicador	Valor
Fallos documentados	6 (3 por integrante)
Preguntas del banco de evaluación	18 (14 con respuesta; 4 de abstención)
Preguntas de abstención ya probadas	1 de 4
Referencias clasificadas	30 (5 por tratamiento y consulta)
Acuerdo bruto entre clasificadores	93,3 % (28/30)
Kappa de Cohen global	$\kappa = -,0345$ ($p = ,85$)
Proporción utilizable, tratamiento A	100 % (10/10)
Proporción utilizable, tratamiento B	100 % (10/10)
Proporción utilizable, tratamiento C	90 % (9/10); IC 95 % [596; 982]
Fuentes del corpus	10
Afirmaciones de las diapositivas 7 a 9 trazadas	8

Nota. IC = intervalo de confianza de Wilson. Los intervalos se recalcularon durante el análisis y coinciden con los reportados.

2. Contexto y alcance

2.1. El propósito manda

Un sistema de IA puede entregar referencias que suenan correctas y no existen, o atribuir a un artículo valores que no contiene. Por eso la regla que organiza la actividad es que ninguna afirmación del anteproyecto se acepta sin una fuente real, localizada y cotejada contra su contenido. La actividad produce tres cosas: un inventario de fallos (qué salió mal y cuánto costó), una evaluación comparada de tres tipos de sistema y un sistema de fuentes con trazabilidad afirmación por afirmación.

2.2. Equipo y herramientas

El equipo lo integran Juan David Cagua y Camilo Velandia. Juan David trabajó con Gemini 3.6 Flash y Camilo con Claude. Para el tratamiento de contexto cerrado se usó NotebookLM con el corpus de PDF del proyecto. La declaración completa del uso de IA está en la Sección 10.

2.3. Marco de referencia

Un sistema de contexto cerrado limita sus respuestas a los documentos que el usuario le carga y, en principio, debe citar con localización exacta dentro de ellos; un sistema abierto responde con conocimiento general o busca en la web. Ambos pueden fallar, pero de maneras distintas: el abierto puede inventar o deformar referencias, y el cerrado puede citar un documento que no está cargado o afirmar algo que el texto no dice. De ahí dos principios que recorren el documento: toda cita se verifica contra el PDF real, y no encontrar algo no equivale a confirmar que no existe.

3. Inventario de fallos

3.1. Qué se registró

La Tabla 2 consolida los inventarios individuales. Cada integrante documentó al menos tres fallos detectados de forma independiente, y el conjunto cubre código, método estadístico, bibliografía, formato de cita y un fallo del propio sistema de contexto cerrado.

Tabla 2. Inventario consolidado de fallos

#	Fallo	Autor	Tipo	Costo	Qué lo habría evitado
1	Función de R mal caracterizada (tidy)	Juan David	Código / herramienta	Tiempo y ajuste manual	Preparar mejor el agente y darle más contexto
2	Regresión politómica en vez de ordinal	Juan David	Conceptual / estadístico	Tiempo de revisión conceptual y cambio de método	Preparar mejor al agente para este tipo de procesos
3	Orden de factores en un gráfico	Juan David	Código (menor)	Tiempo al modificar los factores	Especificar al agente el orden de los niveles
4	Trento citado bajo la cita de Abdelrahman (PDF equivocado en el repositorio)	Camilo	Cita bibliográfica (archivo mal vinculado)	Tiempo de revisión de toda la bibliografía	Verificar cada PDF contra su cita al guardarlo en el repositorio
5	Tres referencias con nombres de autores no occidentales mal formateados (Walsh/Lee, <i>Beyond Accuracy</i> , Xin Yi/Cai)	Camilo	Formato de cita	Tiempo acumulado y revisión	Copiar los nombres directamente desde la página oficial del artículo
6	NotebookLM citó a Miskin et al. sin que ese PDF estuviera en el corpus subido al momento de la consulta	Camilo	Fallo del sistema de contexto cerrado	Tiempo de búsqueda en los PDF	Llevar un registro exacto de qué documentos estaban cargados en el notebook

Nota. Herramientas: Gemini 3.6 Flash (Juan David) y Claude (Camilo).

3.2. Qué enseña el inventario

Los tres fallos de Juan David tienen una causa común: el agente no estaba preparado con el contexto suficiente para la tarea estadística. Los de Camilo se concentran en la gestión bibliográfica y comparten otra: la verificación llegó tarde, cuando ya se habían acumulado errores. En ambos casos el costo principal fue tiempo, y la medida preventiva se puede aplicar en el punto de captura

(contrastar el PDF con su cita al guardarlo, copiar autores desde la página oficial, registrar qué se cargó en cada notebook). El fallo 6 es el más instructivo porque proviene de la herramienta, no de una persona: el equipo lo detectó al buscar en los PDF un valor que el sistema atribuía a un artículo ausente, y de ahí la lección de que no encontrar algo no es lo mismo que confirmar que no existe.

4. Banco de preguntas de evaluación

El banco tiene 18 preguntas con respuesta conocida y ubicada en documento y página del corpus. Las últimas cuatro están fuera del corpus a propósito, para comprobar si el sistema se abstiene o inventa. Cada respuesta esperada se verificó contra el documento (Tabla 3); en la pregunta 2.1 la verificación fue por búsqueda directa al artículo.

4.1. Preguntas con respuesta en el corpus

Tabla 3. Preguntas con respuesta en el corpus (14)

#	Tema	Respuesta esperada	Fuente y ubicación
2.1	Tamaño de LumbarDISC	2.697 pacientes, 8.593 series de imágenes, 8 instituciones, 6 países, 5 continentes	Richards et al. (2026)
2.2	Escala de severidad	Se fusionaron «Normal» y «Leve» para aumentar el consenso entre anotadores; quedan Normal/Leve, Moderada y Severa	Richards et al. (2026), líneas 175 y 528-529 del texto extraído
2.3	Institución colombiana	Fundación Santa Fe de Bogotá; especialista: Dra. Angela Guarnizo Capera	Richards et al. (2026), línea 92 del texto extraído
2.4	Kappa de estenosis del canal, RM vs. MRM	De moderado ($\kappa = ,40$) con RM sola a bueno ($\kappa = ,60$) con mielografía por RM	Al-Tameemi et al. (2017), Tabla 2, pp. 200-201
2.5	Kappa radiólogo–neurocirujano	No mejoró de forma significativa al agregar MRM: se mantuvo bajo ($\kappa = ,33$ a $,38$)	Al-Tameemi et al. (2017), Tabla 2, p. 201
2.6	Muestra de Al-Tameemi et al.	30 pacientes y 150 niveles de disco intervertebral	Al-Tameemi et al. (2017), pp. 198-199
2.7	Mejor arquitectura para estenosis del canal	ViT-L/16, con 92,41 % de precisión de validación (la más alta de las 5 condiciones)	Trînc et al. (2026), tabla de resultados
2.8	Métrica CLOA	Crédito completo a aciertos exactos, parcial a errores adyacentes y cero a diferencias de dos grados; 95,79 % en estenosis del canal	Trînc et al. (2026)
2.9	Factores de riesgo de la estenosis lumbar	Obesidad, tabaquismo y factores genéticos no esclarecidos; la edad es el factor más importante	Bagley et al. (2019), resumen e introducción, pp. 1-3
2.10	Evidencia de nivel I	No hay recomendaciones de nivel I por falta de evidencia concluyente	Bagley et al. (2019), resumen, p. 1

#	Tema	Respuesta esperada	Fuente y ubicación
2.11	Modelo M-SCAN	Modelo multietapa que combina vistas sagitales y axiales con atención cruzada; AUROC de ,971 sobre 1.975 estudios	Citado en Trînc et al. (2026); original: Batra et al. (2025), arXiv:2503.01634
2.12	Estudio de Xin Yi/Cai	Estudio de elementos finitos sobre el efecto biomecánico de la degeneración del disco L4-L5 en la columna lumbar inferior	Cai et al. (2020), título y resumen
2.13	Kappas de Miskin et al.	$\kappa = ,702$ (canal central), ,544 (foraminal), ,557 (artropatía facetaria) y ,323 (receso lateral/subarticular)	Miskin et al. (2021)
2.14	Paradigmas de IA	Modelos híbridos, cascadas multietapa, fusión cross-modal y ensambles; Dice superior a ,90 y AUC de hasta ,98	Abdelrahman et al. (2026)

Nota. RM = resonancia magnética; MRM = mielografía por resonancia magnética.

4.2. Preguntas de abstención

Estas preguntas no tienen respuesta en el corpus. El comportamiento correcto es declarar que la información no está en las fuentes. Solo la primera se ha probado.

Tabla 4. Preguntas de abstención (4)

#	Pregunta	Comportamiento esperado del sistema	Estado
2.15	Prevalencia de la espondilolistesis degenerativa en población colombiana	Decir explícitamente que no está en las fuentes	Probada: NotebookLM se abstuvo y no inventó una cifra
2.16	Primer lugar de la competencia Kaggle RSNA 2024 y su puntaje	Abstenerse: ninguno de los 9 documentos del corpus reporta la tabla de posiciones	Por probar
2.17	Tratamiento de primera línea para estenosis leve según la guía NASS de 2013	Abstenerse o aclarar que solo hay menciones indirectas dentro de Bagley et al. (2019)	Por probar
2.18	Costo promedio de una cirugía de descompresión lumbar en Colombia	Abstenerse: ningún documento trata costos ni el sistema de salud colombiano (Bagley et al. menciona costos en EE. UU.)	Por probar

Nota. NASS = North American Spine Society.

5. El experimento

5.1. Diseño

Se compararon tres tratamientos (Tabla 5) sobre dos consultas bibliográficas reales del área del proyecto: acuerdo interobservador en estenosis lumbar y modelos de aprendizaje profundo sobre el

conjunto RSNA 2024. Se clasificaron 30 referencias en total, cinco por tratamiento y consulta, y cada una la clasificaron los dos integrantes de forma independiente como utilizable o no utilizable.

Tabla 5. Tratamientos del experimento

Tratamiento	Descripción	Referencias clasificadas
A	Chat sin fuentes (control)	10 (5 por consulta)
B	Buscador con bases de datos reales	10 (5 por consulta)
C	Contexto cerrado: NotebookLM con el corpus del equipo	10 (5 por consulta)

5.2. Resultados


El acuerdo bruto entre clasificadores fue de 93,3 % (28/30). El kappa de Cohen global fue de $-.0345$ ($p = .85$). Las proporciones utilizables y sus intervalos de Wilson al 95 % se presentan en la Tabla 6 y en la Figura 1.

Tabla 6. Proporción de referencias utilizables por tratamiento

Tratamiento	N total	N utilizable	Proporción	IC inferior	IC superior
A	10	10	1,000	,722	1,000
B	10	10	1,000	,722	1,000
C	10	9	,900	,596	,982

Nota. IC = intervalo de confianza de Wilson al 95 %.

Figura 1. Proporción de referencias utilizables por tratamiento



Nota. Las barras de error son intervalos de confianza de Wilson al 95 %. A = chat sin fuentes; B = buscador con bases reales; C = contexto cerrado.

5.3. Interpretación

El único caso no utilizable reveló un fallo real y documentado: NotebookLM citó valores de Miskin et al. (2021), un artículo que no estaba en el corpus en el momento de la consulta. Los dos integrantes confirmaron con fecha exacta que el PDF se subió un día después. El artículo sí respalda el contenido de la diapositiva 8.1, así que el problema es del sistema y no de la bibliografía.

Respecto del kappa, el equipo señala que el valor negativo pese al alto acuerdo es un artefacto estadístico esperable cuando casi todas las referencias caen en una sola categoría, y que no indica desacuerdo real. Esa explicación es correcta en lo general; la Sección 9 añade una verificación aritmética sobre qué configuración de clasificaciones produce exactamente ese valor.

6. Herramienta elegida y comparación

Se comparó NotebookLM con la alternativa de un proyecto con archivos (Claude o ChatGPT Projects) en seis criterios (Tabla 7). NotebookLM gana en tres, empata en dos y pierde en uno. Se eligió principalmente por su capacidad de citar con localización exacta dentro del documento, que se verificó en la práctica durante el experimento.

Tabla 7. Comparación de NotebookLM con un proyecto con archivos

Criterio	Resultado	Comentario
Contexto cerrado	Gana NotebookLM	—
Cita con localización	Gana NotebookLM	Criterio decisivo en la elección
Costo	Gana NotebookLM	—
Privacidad	Empate*	—
Exportación APA 7	Empate*	—
Reproducibilidad	Gana el proyecto con archivos	Se compensa documentando por escrito el protocolo de prompts (Sección 8)

Nota. La actividad no nombra los dos empates; se infieren por eliminación, porque los otros cuatro criterios tienen resultado explícito

7. Sistema de fuentes

7.1. Tabla de fuentes

El corpus del proyecto reúne diez fuentes (Tabla 8). Los DOI de cada una están en la lista de referencias.

Tabla 8. Fuentes del corpus

#	Archivo	Enfoque	Autores y año
1	073c3e60427a...	Graduación simplificada en RM lumbar	Miskin et al. (2021)
2	A_Comprehensive...	Revisión integral de IA en RM lumbar	Abdelrahman et al. (2026)

#	Archivo	Enfoque	Autores y año
3	Anatomy-guided...	Aprendizaje profundo guiado por anatomía	Chai et al. (2026)
4	OS-12-917.pdf	Efecto biomecánico en elementos finitos (L4-L5)	Cai et al. (2020)
5	The_RSNA_Lumbar...	Conjunto de datos RSNA LumbarDISC	Richards et al. / RSNA (2026)
6	al-tameemi_2017...	Mielografía por RM y acuerdo interobservador	Al-Tameemi et al. (2017)
7	bagley_2019.pdf	Conceptos y manejo de la estenosis lumbar	Bagley et al. (2019)
8	s00586-025-09179-z.pdf	Avances y desafíos en la resonancia asistida por IA	Zhao et al. (2025)
9	beyond_accuracy...	Vision Transformers y métricas ordinales	Trînc et al. (2026)
10	medicina-61...	IA en patología degenerativa lumbar (revisión)	Trento et al. (2025)

7.2. Tabla de trazabilidad

La Tabla 9 cubre las diapositivas 7, 8 y 9 del anteproyecto. Por cada afirmación indica qué fuente cita la diapositiva, si esa fuente es real y si su contenido respalda lo que se afirma. Convención: *Coincide* (la fuente real dice lo que se le atribuye), *Sin confirmar* (la fuente parece correcta pero no se cotejó el contenido exacto) y *No coincide* (hay un problema de atribución). Las afirmaciones están resumidas, no transcritas; las fechas y los responsables de la verificación provienen del registro de la actividad.

Tabla 9. Trazabilidad de las afirmaciones de las diapositivas 7 a 9

#	Afirmación	Fuente citada	¿Fuente real?	¿Coincide el contenido?	Verificación
7.1	Evaluar estas condiciones con métodos básicos es insuficiente por el desbalance de datos; se proponen modelos estadísticos para perfiles completos	Bibliografía: «Preprints (2026)», sin autores	Sí, la plataforma es real; los autores reales (Trînc, Ancuți, Ancuți e Iacob) se omitieron	Sin confirmar (parcial). El método real son cinco pipelines de Vision Transformers con 24 configuraciones cada uno	Leído completo, pp. 1-2; 24-sep-2026
7.2	Los modelos de IA transforman el diagnóstico y pronóstico de estenosis espinal y hernias discales, y agilizan el flujo de trabajo	Abdelrahman et al. (2026), «J. Software Engineering and Applications»	Sí; la revista real es <i>Journal of Smart Algorithms and Applications</i>	Sin confirmar. Es plausible, pero falta el cotejo línea por línea con la diapositiva	Juan David y equipo; 26-sep-2026

#	Afirmación	Fuente citada	¿Fuente real?	¿Coincide el contenido?	Verificación
7.3	Algunas patologías pueden tener una misma causa de origen y relacionarse	Furman (2024), <i>Spinal Stenosis</i> , Medscape	Existe, pero es fuente terciaria con acceso restringido	Sin confirmar (barrera de acceso)	Retirada el 2-oct-2026 (Juan David)
8.1	Desarrollado por especialistas de varias disciplinas; compara concordancia entre especialidades y no solo entre radiólogos	Miskin et al. (2021)	Sí: <i>Pain Medicine</i> , DOI 10.1093/pm/pnab098	Coincide. El fallo fue del sistema: el PDF no estaba cargado en el notebook al correr el tratamiento C	26-sep-2026
8.2	Combina mielografía y resonancia magnética	Al-Tameemi et al. (2017)	Sí: <i>Asian Spine Journal</i>	Coincide , aunque la síntesis de la diapositiva es muy pobre	Leído completo, pp. 200-201 (Tablas 2 y 3); 24-sep-2026
8.3	Con 37 médicos de seis especialidades, revisa la exactitud preintervención con y sin capacitación	Walsh et al. (2026)	Sí: <i>Academic Radiology</i> ; autores mal separados en la bibliografía	Coincide (vía resumen): exactitud de 54,5 % a 61,2 % tras capacitación estructurada	22-sep-2026; cita por corregir
9.1	Aprendizaje profundo guiado por la anatomía para clasificar la patología y evaluar el riesgo	Chai et al. (2026), <i>Frontiers in Medicine</i>	Sí: DOI 10.3389/fmed.2026.1848548; publicado el 26-jun-2026	Coincide. Marco de tres etapas; macro F1 = ,783; κ = ,765; AUC por paciente = ,891	26-sep-2026
9.2	Avances y conceptos para entender y tratar la estenosis, con mejoras en tratamientos	Bagley et al. (2019)	Sí: <i>F1000Research</i>	Coincide. No hay recomendaciones de nivel I; la diapositiva no lo menciona, pero no lo contradice	Leído completo, pp. 1 y 4-5; 24-sep-2026

8. Protocolo de prompts (v1.0)

El protocolo fija cómo debe comportarse el agente de consultoría para que el uso de IA sea reproducible y verificable. Se emitió el 27 de septiembre de 2026 (Tabla 10).

Tabla 10. Componentes del protocolo de prompts v1.0

Componente	Contenido
Sistema	Agente de Consultoría Bioestadística (estenosis lumbar / RSNA 2024)
Versión y fecha	v1.0, 27 de septiembre de 2026
Rol	Consultor bioestadístico senior especializado en análisis clínico e interpretación de datos de resonancia magnética para estenosis lumbar, con asistencia rigurosa, transparente y metodológicamente reproducible

Componente	Contenido
Corpus autorizado	Únicamente los PDF del estado del arte almacenados en la biblioteca del proyecto y el conjunto tabular de Kaggle (RSNA 2024)
Restricción	Prohibido usar conocimiento general no verificado para emitir juicios clínicos o estadísticos específicos del corpus
Formato de cita	[Autor, Año] + (Documento, página o sección exacta), obligatorio para toda afirmación, métrica o hallazgo
Abstención	Si la respuesta no está explícita en el corpus o los datos, responder: «La información solicitada no se encuentra disponible en las fuentes documentales ni en los datos provistos por el corpus del proyecto»
Historial	v1.0: directrices sobre restricción de fuentes y obligatoriedad de abstención ante vacíos informativos

9. Observaciones del análisis y acciones pendientes

Nota del análisis

Esta sección es resultado del análisis del documento de la actividad; no forma parte de su versión original. La prioridad es un juicio del análisis, no del equipo.

9.1. Observaciones

Tabla 11. Observaciones, prioridad y acción sugerida

#	Observación	Prioridad	Acción sugerida
01	El kappa de $-0,0345$ con 28/30 acuerdos solo se obtiene, con dos categorías, si cada integrante marcó como no utilizable una referencia distinta ($p_0 = 28/30$; $p_e = (29/30)^2 + (1/30)^2 \approx ,9356$; $\kappa \approx -0,0345$). La actividad dice que ambos confirmaron el caso de Miskin et al., lo que daría un kappa distinto	Alta	Publicar la matriz 2×2 de clasificación, recalcular y aclarar si hubo más de dos categorías. Reportar además acuerdo positivo y negativo, PABAK o AC1 de Gwet
02	El criterio «utilizable» no está definido. Que A (chat sin fuentes) y B alcancen 100 % sugiere que mide existencia o pertinencia y no fidelidad del contenido	Alta	Definir criterios operativos (existe, metadatos correctos, el contenido respalda la afirmación) y reportarlos por separado
03	Con $n = 10$ por tratamiento y un caso negativo, los intervalos de A/B $[,722; 1,000]$ y C $[,596; ,982]$ se solapan; no hay base para declarar diferencias	Media	Presentar el experimento como exploratorio o ampliar la muestra antes de comparar

#	Observación	Prioridad	Acción sugerida
04	El conteo del corpus no cuadra: la pregunta 2.16 habla de 9 documentos y la Tabla 8 lista 10 (Miskin et al. se cargó un día después). Walsh et al. y Furman no están en la tabla	Media	Registrar la versión del corpus con la fecha de carga de cada PDF
05	Solo una de las cuatro preguntas de abstención se ha probado	Alta	Ejecutar 2.16 a 2.18 con el protocolo v1.0 y registrar las respuestas
06	Verificaciones incompletas: 7.2 sin cotejo línea por línea; 8.3 solo por resumen; 7.1 coincide en parte; 7.3 sin fuente sustituta	Alta	Leer los PDF completos y reemplazar la fuente de 7.3 o ajustar la diapositiva
07	Referencias con autores incompletos («et al.»), «Preprints» como autor, revista equivocada y nombres no occidentales mal separados	Media	Completar la lista de autores desde la página oficial (APA 7 admite hasta 20)
08	El formato de cita del protocolo, [Autor, Año] + (Documento, página), no es APA 7	Baja	Cambiar a (Autor, año, p. X) en la v1.1 y registrarlo en el historial
09	Dos preguntas (2.2 y 2.3) se localizan por «línea del texto extraído», que no se puede ubicar en el PDF	Baja	Agregar la página del PDF
010	El documento original tenía una frase truncada en el inventario y errores de tipeo (por ejemplo, «compensadadocumentando»)	Baja	Corregidos al consolidar este documento

Nota. Prioridad: Alta = afecta una conclusión del experimento o la validez de una cita; Media = afecta la solidez; Baja = forma.

9.2. Qué permite concluir el experimento

Los intervalos de Wilson se recalcularon y son correctos: ,722 a 1,000 para 10/10 y ,596 a ,982 para 9/10. Lo que el experimento sí muestra es un hallazgo cualitativo sólido, el de que un sistema de contexto cerrado puede citar un documento que no tiene cargado, y por eso conviene registrar la versión del corpus. Lo que no muestra es una ventaja o desventaja de ningún sistema: con un efecto techo (100 % en A y B) y un solo caso negativo, la prueba no discrimina.

9.3. Acciones pendientes

- Reconstruir la matriz de clasificación y recalcular el acuerdo (01).
- Probar las preguntas de abstención 2.16 a 2.18 (05).
- Cerrar las verificaciones de 7.1, 7.2, 7.3 y 8.3 (06).
- Completar autores y títulos de la lista de referencias (07).
- Emitir la v1.1 del protocolo con cita APA 7 (08).

10. Declaración del uso de IA

Se usaron Google Gemini 3.6 Flash y Claude Sonnet 5.5 como herramientas de apoyo para hacer el código ejecutable y resolver consultas técnicas. Lo que arrojaron no se incorporó de inmediato: se revisó primero mediante la ejecución del código y la revisión de fuentes y recursos. El agente de IA no emitió diagnósticos médicos ni recomendaciones clínicas; solo hizo análisis bioestadístico de datos según los requerimientos.

10.1. Qué partes del trabajo se hicieron con ayuda de IA

El proyecto usó inteligencia artificial en dos niveles distintos, que conviene no mezclar:

El agente de consultoría bioestadística (gemini-3.6-flash, vía API), construido por el equipo como el objeto de estudio del anteproyecto original — recomendó pruebas estadísticas, código en R y pasos de análisis para el dataset RSNA LumbarDISC.

Claude (Anthropic), usado durante esta actividad como asistente de trabajo para:

- Auditar el anteproyecto y el repositorio del agente contra las fuentes primarias,
- Diseñar y documentar el experimento de tres tratamientos (A/B/C),
- Construir el corpus, la tabla de trazabilidad, el protocolo de prompts y el banco de preguntas,
- Correr el análisis estadístico (kappa de Cohen, intervalos de Wilson) y redactar los documentos de entrega (inventario de fallos, memoria, exposición, este mismo archivo).

NotebookLM (Google), elegido como el sistema final con cita obligatoria — ancla sus respuestas a los 10 documentos del corpus y es el sistema evaluado en el experimento y en el banco de 18 preguntas.

Ningún texto generado por IA se usó sin que un integrante del equipo lo contrastara contra la fuente primaria antes de incluirlo en un entregable. Esa verificación —no la generación— es el trabajo que hizo el equipo.

10.2. Qué controles usamos

Verificación documento por documento: cada referencia de la bibliografía original se abrió y se leyó, no se asumió correcta por tener formato de cita.

Clasificación independiente y doble: en el experimento de 30 referencias, cada integrante clasificó sin ver la clasificación del otro; solo después se compararon y se calculó el acuerdo (kappa de Cohen).

Verificación línea por línea con pdftotext: para afirmaciones específicas (cifras, nombres, kappas), se extrajo el texto exacto del PDF y se comparó carácter por carácter con lo citado por la IA, no solo "a simple vista".

Protocolo de cita obligatoria: se exigió a NotebookLM citar documento y ubicación exacta, y se definió una regla explícita de abstención para cuando la respuesta no está en el corpus.

Pruebas de estrés deliberadas: 4 de las 18 preguntas del banco final se diseñaron sin respuesta en el corpus, específicamente para ver si el sistema inventaba en vez de abstenerse.

10.3. Cuando la IA se equivocó (y que hicimos)

Documentamos tres casos distintos, porque cada uno enseña algo diferente:

Caso 1: NotebookLM citó contenido fuera de su propio corpus (semana 2). Con el corpus en 6 documentos, le pedimos kappas de acuerdo entre lectores. Respondió con valores específicos (0.702, 0.544, 0.557, 0.323) como si vinieran de las fuentes cargadas. No estaban en ninguno de los 6 PDF. Resultaron ser reales, pero de un artículo (Miskin et al., 2021) que aún no estaba en el sistema. Lo agregamos al corpus, repetimos la pregunta, y en la semana 3 el sistema citó a Miskin correctamente, con ubicación exacta. Quedó documentado el ciclo completo: detectar → diagnosticar → corregir → volver a probar.

Caso 2: Claude generó una cita no verificada (autocorregido antes de entregar). En un borrador intermedio de uno de los archivos de corpus, Claude incluyó un DOI para una referencia sin haberlo verificado de verdad. Se detectó al revisar el archivo antes de entregarlo al equipo, se corrigió, y se informó explícitamente en la conversación en vez de dejarlo pasar. No llegó a ningún entregable final.

Caso 3: Una conclusión de "no localizable" resultó ser un error de búsqueda, no una invención. Tras tres búsquedas externas sin resultado, se concluyó que la referencia "Chai et al." era candidata a fabricación. Juan David encontró después el artículo real (DOI 10.3389/fmed.2026.1848548) en una fuente que las búsquedas anteriores no habían cubierto. Se corrigió la conclusión en todos los documentos afectados y se reemplazó por otro hallazgo real. La lección: una búsqueda fallida no es evidencia de que algo no exista, y hay que decirlo así en vez de presentar una ausencia como una prueba.

10.4. Qué no hicimos

- No se usó ninguna cifra, cita o afirmación generada por IA sin verificarla contra una fuente primaria accesible al equipo.
- No se corrigió ningún fallo "hacia adentro" (ocultándolo o suavizándolo) — los tres casos anteriores están documentados con fecha, evidencia y quién lo verificó.
- No se promedian clasificaciones en desacuerdo entre los dos integrantes: cuando Juan David y Camilo no coincidieron (2 de 30 casos en el experimento), se resolvió con una discusión razonada y documentada, no con un criterio automático.

10.5. Responsables

Documento preparado conjuntamente por Juan David Cagua y Camilo Velandia, con asistencia de Claude (Anthropic) para la redacción y de NotebookLM (Google) como sistema evaluado. La verificación de cada afirmación contra las fuentes primarias fue realizada por los integrantes del equipo.

Referencias

Nota. La revista y el volumen de Cai et al., Richards et al., Trento et al. y Zhao et al. se infieren del DOI y del nombre del archivo.

Abdelrahman, et al. (2026). *Journal of Smart Algorithms and Applications*.

<https://doi.org/10.66279/r8h6j935>

Al-Tameemi, H. N., et al. (2017). *Asian Spine Journal*, 11(2), 198–[...].

<https://doi.org/10.4184/asj.2017.11.2.198>

Bagley, C., et al. (2019). *F1000Research*. <https://doi.org/10.12688/f1000research.16082.1>

Batra, et al. (2025). A Multistage Framework for Lumbar Spinal Canal Stenosis Grading Using Multi-View Cross Attention. *arXiv*. <https://doi.org/10.48550/arXiv.2503.01634>

Cai, et al. (2020). *Orthopaedic Surgery*, 12, 917–[...]. <https://doi.org/10.1111/os.12703>

Chai, Z., Liu, Qin, Zhao, & Shi et al. (2026). *Frontiers in Medicine*.

<https://doi.org/10.3389/fmed.2026.1848548>

Furman, M. B. (2024). *Spinal stenosis*. Medscape. [Fuente retirada de la diapositiva 7.3 por ser terciaria]

Miskin, N., et al.. (2021). *Pain Medicine*. <https://doi.org/10.1093/pm/pnab098>

Richards, et al. (2026). *Radiology: Artificial Intelligence*. <https://doi.org/10.1148/ryai.250480>

Trento, et al. (2025). *Medicina*, 61. <https://doi.org/10.3390/medicina61081400>

Trînc, E. C., et al. (2026). Beyond Accuracy: Multi-Level Ordinal Assessment of Lumbar Spine Degeneration from Multiplanar MRI Using the RSNA 2024 (LumbarDISC) Dataset and Condition-Specific ViTs. *Preprints*. <https://doi.org/10.20944/preprints202608.1250.v1>

Walsh, P. J., et al. (2026). Improving Reliability of MRI Lumbar Spinal Stenosis Assessment Across Radiology and Spine Specialties: Impact of a Structured Education Intervention. *Academic Radiology*. PubMed. <https://doi.org/10.1016/j.acra.2026.06.021>

Zhao, et al. (2025). *European Spine Journal*. <https://doi.org/10.1007/s00586-025-09179-z>

Anexo A

Glosario

Tabla A1. Términos usados en este documento

Término	Significado aquí
Contexto cerrado	Sistema que responde solo con los documentos que el usuario le carga
Corpus	Conjunto de documentos del proyecto contra el cual se verifican las respuestas
Tratamiento	Cada condición comparada en el experimento (A, B o C)
Utilizable	Referencia que los clasificadores consideraron aprovechable; el criterio exacto no está definido en la actividad (O2)
Abstención	Respuesta explícita de que la información no está en las fuentes, en lugar de inventarla
Trazabilidad	Posibilidad de seguir cada afirmación hasta su fuente y comprobar que la respalda
Fuente terciaria	Enciclopedia o resumen que compila estudios originales (por ejemplo, Medscape)
Preprint	Manuscrito difundido antes de su revisión por pares
Intervalo de Wilson	Intervalo de confianza para una proporción, apropiado con muestras pequeñas y proporciones cercanas a 0 o 1
Kappa de Cohen	Medida de acuerdo entre dos clasificadores corregida por el azar
Paradoja del kappa	Kappa bajo o negativo pese a un acuerdo bruto alto cuando casi todos los casos caen en una categoría
Efecto techo	Valores cercanos al máximo posible que impiden distinguir entre grupos
DOI	Identificador permanente de un artículo

Anexo B

Cifras clave

Tabla B1. Cifras clave y su origen

Cifra	Valor	Sección
Fallos documentados	6	3
Preguntas del banco	18 (14 + 4)	4
Referencias clasificadas	30	5
Acuerdo bruto entre clasificadores	93,3 % (28/30)	5
Kappa de Cohen global	-,0345 (p = ,85)	5, 9
Proporción utilizable A / B / C	100 % / 100 % / 90 %	5
IC de Wilson de C	[,596; ,982]	5, 9
Fuentes del corpus	10	7
Afirmaciones trazadas	8	7
Versión del protocolo	v1.0 (27-sep-2026)	8
Observaciones del análisis	10	9